

Taller grupal. Creación de una base de datos genómica

Bases de Datos y Recursos Bioinformáticos • MUBIO06

Integrantes: Rubén Juárez Cádiz • [Integrante 2] • [Integrante 3] • [Integrante 4]

Se diseña una base de datos relacional genómica completa en MySQL 8.0+, con especial atención a normalización, integridad referencial, restricciones explícitas del enunciado y pruebas controladas de error.

1. Análisis de requerimientos

- La unidad principal es el gen. Cada gen tiene un nombre único y una descripción obligatoria, y se localiza en un intervalo cromosómico con hebra.
- Cada gen puede contener múltiples secuencias. Una secuencia almacena ADN, un tipo (exón, intrón, CDS, promotor, UTR u otra categoría) y una posición relativa al gen.
- Las variantes se sitúan dentro de una secuencia y almacenan posición relativa, alelo de referencia, alelo alternativo y tipo de cambio.
- Las anotaciones se modelan como entidades reutilizables y pueden relacionarse con genes y variantes.
- Los estudios se relacionan de forma N:M con genes y variantes, permitiendo que un estudio cubra varias entidades y que una entidad aparezca en varios estudios.

1.1. Restricciones identificadas

ID	Regla	Mecanismo
R1	ADN entre 10 y 1000 caracteres.	CHECK
R2	Nombre y descripción del gen obligatorios; nombre único.	NOT NULL + UNIQUE
R3	Referencia de estudio con patrón cuatro letras / tres números.	CHECK REGEXP
R4	Alelos con valor por defecto «-».	DEFAULT
R5	Posiciones relativas positivas y no nulas.	CHECK
R6	ADN limitado a A, C, G, T y N.	CHECK REGEXP
R7	Intervalo del gen coherente: fin $\geq$ inicio.	CHECK
R8	Secuencia dentro de la longitud relativa del gen.	TRIGGER
R9	Variante dentro de la longitud de su secuencia.	TRIGGER
R10	Integridad referencial y ausencia de relaciones N:M duplicadas.	PK/FK + PK compuestas

2. Diseño E-R

El modelo conceptual contiene cinco entidades principales y cuatro entidades asociativas para resolver las relaciones N:M. La cardinalidad GEN-SECUENCIA y SECUENCIA-VARIANTE es 1:N.




Figura 1. Modelo E-R propuesto con PK/FK y cardinalidades.

3. Transformación al modelo relacional

Relación	Atributos y claves
GEN	gen_id PK; nombre UQ; descripcion; cromosoma; posicion_inicio; posicion_fin; hebra
SECUENCIA	secuencia_id PK; gen_id FK; tipo; adn; posicion_relativa; longitud GENERATED
VARIANTE	variante_id PK; secuencia_id FK; posicion_relativa; alelo_referencia; alelo_alternativo; tipo
ANOTACION	anotacion_id PK; tipo; descripcion
ESTUDIO	estudio_id PK; titulo; fecha_publicacion; referencia UQ
GEN_ANNOTACION	gen_id PK/FK; anotacion_id PK/FK
VARIANTE_ANNOTACION	variante_id PK/FK; anotacion_id PK/FK
ESTUDIO_GEN	estudio_id PK/FK; gen_id PK/FK
ESTUDIO_VARIANTE	estudio_id PK/FK; variante_id PK/FK

Normalización: el diseño alcanza 3FN. No se almacenan atributos multivaluados; las relaciones N:M se descomponen en tablas puente; y VARIANTE no duplica gen_id, ya que la pertenencia al gen se deriva inequívocamente mediante SECUENCIA.

4. Creación de la base de datos en MySQL

La solución completa está en sql/01_schema.sql. A continuación se muestran los fragmentos que materializan las restricciones de mayor interés.

```
CREATE TABLE `secuencia` (  
  `secuencia_id` BIGINT UNSIGNED NOT NULL AUTO_INCREMENT,  
  `gen_id` BIGINT UNSIGNED NOT NULL,  
  `tipo` ENUM('EXON','INTRON','CDS','PROMOTOR','UTR','OTRA') NOT NULL,  
  `adn` VARCHAR(1000) NOT NULL,  
  `posicion_relativa` INT UNSIGNED NOT NULL,  
  `longitud` SMALLINT UNSIGNED GENERATED ALWAYS AS (CHAR_LENGTH(`adn`)) STORED,  
  PRIMARY KEY (`secuencia_id`),  
  FOREIGN KEY (`gen_id`) REFERENCES `gen` (`gen_id`) ON DELETE CASCADE,  
  CHECK (CHAR_LENGTH(`adn`) BETWEEN 10 AND 1000),  
  CHECK (BINARY `adn` REGEXP '^[ACGTN]+$'),  
  CHECK (`posicion_relativa` > 0)  
);  
  
CREATE TABLE `estudio` (  
  `estudio_id` BIGINT UNSIGNED NOT NULL AUTO_INCREMENT,  
  `titulo` VARCHAR(300) NOT NULL,  
  `fecha_publicacion` DATE NOT NULL,  
  `referencia` CHAR(8) NOT NULL UNIQUE,  
  PRIMARY KEY (`estudio_id`),  
  CHECK (BINARY `referencia` REGEXP '^([A-Za-z]{4})/([0-9]{3})$')  
);  
  
CREATE TABLE `variante` (  
  ...  
  `alelo_referencia` VARCHAR(255) NOT NULL DEFAULT '-',  
  `alelo_alternativo` VARCHAR(255) NOT NULL DEFAULT '-',  
  ...  
  CHECK (`posicion_relativa` > 0),  
  CHECK (BINARY `alelo_referencia` REGEXP '^(-|[ACGTN]+)$'),  
  CHECK (BINARY `alelo_alternativo` REGEXP '^(-|[ACGTN]+)$')  
);
```

4.1. Restricciones entre tablas mediante triggers

```
CREATE TRIGGER `trg_variante_bi`  
BEFORE INSERT ON `variante`  
FOR EACH ROW  
BEGIN  
    DECLARE v_longitud_secuencia INT UNSIGNED;  
    SELECT `longitud` INTO v_longitud_secuencia  
    FROM `secuencia` WHERE `secuencia_id` = NEW.`secuencia_id`;  
    IF NEW.`posicion_relativa` > v_longitud_secuencia THEN  
        SIGNAL SQLSTATE '45000'  
        SET MESSAGE_TEXT = 'La variante queda fuera de la secuencia asociada';  
    END IF;  
END;
```

[CAPTURA REAL MYSQL WORKBENCH • creación de tablas + SHOW CREATE TABLE + SHOW TRIGGERS]

5. Inserción manual de datos

Se introducen datos sintéticos manuales: 3 genes, 6 secuencias, 5 variantes, 5 anotaciones, 4 estudios y las relaciones N:M necesarias. Los nombres HBB_DEMO, CFTR_DEMO y BRCA1_DEMO se usan solo con finalidad docente; las coordenadas y registros son sintéticos.

```
INSERT INTO `gen`  
(`gen_id`,`nombre`,`descripcion`,`cromosoma`,`posicion_inicio`,`posicion_fin`,`hebra`) VALUES  
(1,'HBB_DEMO','Gen sintético inspirado en beta-globina para demostrar el modelo  
relacional.','11',100000,101600,'-'),  
(2,'CFTR_DEMO','Gen sintético inspirado en CFTR para pruebas de secuencias y  
variantes.','7',200000,220000,'+'),  
(3,'BRCA1_DEMO','Gen sintético inspirado en BRCA1 para ilustrar anotaciones  
clínicas.','17',300000,315000,'-');
```

Tabla	Filas esperadas
gen	3
secuencia	6
variante	5
anotacion	5
estudio	4
gen_anotacion	6
variante_anotacion	5
estudio_gen	6
estudio_variante	8

[CAPTURA REAL MYSQL WORKBENCH • inserciones válidas + consulta V01/V02]

6. Pruebas de restricciones e inserciones incorrectas

El fichero sql/03_pruebas_restricciones.sql ejecuta cada caso dentro de una transacción que se revierte y captura la excepción. De este modo se documentan errores sin dejar basura en la base de datos.

Prueba	Caso	Esperado
P01	ADN < 10	RECHAZADO
P02	ADN > 1000	RECHAZADO
P03	Descripción de gen NULL	RECHAZADO
P04	Referencia ABC/12	RECHAZADO
P05	Posición de secuencia = 0	RECHAZADO
P06	ADN con XYZ	RECHAZADO
P07	Variante fuera de secuencia	RECHAZADO
P08	Nombre de gen duplicado	RECHAZADO
P09	Alelos omitidos adoptan -	ACEPTADO

[CAPTURA REAL MYSQL WORKBENCH • tabla resultado_pruebas_restriccion P01-P09]

7. Verificación de relaciones y consultas

Las consultas V02-V05 demuestran que las relaciones pueden recorrerse sin redundancia: gen→secuencia→variante; gen ↔ anotación; estudio ↔ gen; y estudio ↔ variante. Las tablas puente admiten N:M reales y sus PK compuestas impiden duplicar el mismo vínculo.

```
SELECT g.nombre AS gen, s.secuencia_id, s.tipo, v.variante_id,
       v.posicion_relativa, v.alelo_referencia, v.alelo_alternativo
FROM gen g
JOIN secuencia s ON s.gen_id = g.gen_id
LEFT JOIN variante v ON v.secuencia_id = s.secuencia_id
ORDER BY g.gen_id, s.secuencia_id, v.variante_id;
```

[CAPTURA REAL MYSQL WORKBENCH • consultas V03/V04/V05]

8. Conclusiones y cobertura de la rúbrica

El diseño satisface el dominio solicitado y refuerza la integridad de los datos con normalización y controles semánticos. Las restricciones se han transformado en mecanismos ejecutables y pruebas reproducibles, lo que permite demostrar no solo que las inserciones válidas funcionan, sino también que los errores esperados son bloqueados por el propio SGBD.

Criterio	Cobertura	Evidencia
Modelo E-R	3/3	Entidades, atributos, cardinalidades y tablas asociativas.
Modelo relacional	2/2	3FN, nomenclatura consistente y relaciones N:M sin redundancia.
SQL y restricciones	3/3	PK/FK, CHECK, DEFAULT, UNIQUE, ENUM, índices y triggers.
Inserciones y errores	2/2	Datos manuales + 9 pruebas, con 8 rechazos y 1 aceptación controlada.

Antes de entregar: sustituir los marcadores rojos por capturas auténticas de MySQL Workbench y completar los nombres/contribuciones reales del equipo. Mantener Calibri 12, interlineado simple y un máximo de 20 páginas.